

Riassunto teoria Basi di Dati

Angelo Vaccaro

Indice

1	Introduzione e Sistemi Informativi	3
2	Ciclo di Vita e Progettazione	4
3	Progettazione Concettuale (Modello E-R)	4
4	Progettazione Logica (Modello Relazionale)	5
5	Progettazione Logica dallo Schema Concettuale	6
6	Tecnologie NoSQL: Sistemi Document Based	7
7	Algebra Relazionale	8

1 Introduzione e Sistemi Informativi

Concetti Chiave

Il corso inizia distinguendo tra il concetto di dato e informazione. Un Sistema Informativo è l'infrastruttura (non necessariamente informatica) che gestisce le informazioni di un'organizzazione. Quando queste informazioni sono gestite tramite tecnologia informatica e persistente, si parla di Base di Dati.

L'approccio tradizionale basato sui file presenta limiti critici: accesso sequenziale inefficiente, ridondanza (duplicazione), inconsistenza (aggiornamenti parziali) e dipendenza stretta tra dati e applicazioni.

Per risolvere ciò, si utilizzano i DBMS (Data Base Management System), software che fungono da intermediari tra le applicazioni e i dati fisici, garantendo affidabilità, privacy ed efficienza.

Lo schema di una base di dati è organizzato su tre livelli di astrazione per garantire l'indipendenza dei dati:

- **Schema Esterno:** Come l'utente vede i dati (viste personalizzate).
- **Schema Logico:** La struttura globale logica dei dati (indipendente dalla fisica).
- **Schema Interno:** La rappresentazione fisica effettiva in memoria.

Definizioni

- **Base di Dati:** "Una collezione di dati persistenti utilizzati per rappresentare con tecnologia informatica le informazioni di interesse per un sistema informativo".
- **DBMS:** "Un sistema che gestisce su memoria secondaria collezioni di dati... Le caratteristiche principali sono: Grandi, Condivise, Persistenti".
- **Modello dei dati:** "Un insieme di strutture che permettono di descrivere una base di dati" (es. Relazionale, NoSQL, Gerarchico),.

Dettagli Minori

I linguaggi del DBMS si dividono in DDL (Data Definition Language) per definire la struttura e DML (Data Manipulation Language) per interrogare/aggiornare i dati. Proprietà fondamentali: Indipendenza fisica (modifiche fisiche non impattano lo schema logico) e Indipendenza logica (modifiche logiche non impattano le viste esterne).

2 Ciclo di Vita e Progettazione

Concetti Chiave

La creazione di una base di dati non è un evento isolato ma un processo ingegneristico diviso in fasi. Si parte dallo studio di fattibilità e dalla raccolta dei requisiti, per poi passare alla progettazione vera e propria, che procede parallelamente per i dati e per le applicazioni,.

Le tre fasi della progettazione dei dati sono:

- **Progettazione Concettuale:** Produce uno schema formale (es. ER) indipendente dalla tecnologia scelta. Rappresenta il "cosa".
- **Progettazione Logica:** Traduce lo schema concettuale nel modello del DBMS scelto (es. tabelle relazionali), considerando anche le prestazioni.
- **Progettazione Fisica:** Ottimizza l'accesso ai dati (es. indici) a livello di memoria.

Definizioni

Analisi di qualità dello schema: Processo per verificare la bontà dello schema concettuale basato su:

- **Correttezza:** Uso corretto dei costrutti (sintattica e semantica).
- **Completezza:** Tutti i requisiti sono rappresentati.
- **Minimalità:** Assenza di ridondanze (concetti rappresentati una sola volta).
- **Leggibilità:** Chiarezza dello schema.

Dettagli Minori

Le strategie di progettazione includono: Top-Down (dal generale al dettaglio), Bottom-Up (dalle parti elementari all'insieme), Inside-Out (dai concetti guida verso l'esterno). Possibili ridondanze da evitare: cicli di relazioni (se una relazione è derivabile dalla composizione di altre) e ereditarietà ridondante,.

3 Progettazione Concettuale (Modello E-R)

Concetti Chiave

Il modello Entità-Relazione è lo standard per la progettazione concettuale. È puramente descrittivo e non considera vincoli tecnologici.

- **Entità:** Rappresentano classi di oggetti con esistenza autonoma e proprietà comuni. Sono contenitori logici di istanze (es. l'entità Persona contiene l'istanza Mario Rossi),.

- **Relazioni:** Rappresentano legami logici tra entità. Un'istanza di relazione è una combinazione di istanze delle entità coinvolte,.
- **Attributi:** Proprietà elementari che associano un valore a un'istanza (es. Nome, Data). Possono essere composti (es. Indirizzo formato da Via e Civico),.

Definizioni

- **Identificatore:** "Un insieme di proprietà (attributi e/o relazioni) che identificano univocamente ogni istanza di E". Può essere interno (solo attributi) o esterno (coinvolge relazioni).
- **Cardinalità:** Vincoli (min, max) che indicano quante volte un'istanza di un'entità può o deve partecipare a una relazione.
 - min=0 (opzionale), min=1 (obbligatorio).
 - max=1 (al massimo una), max=N (arbitrario),.
- **Generalizzazione:** Un legame logico (ereditarietà) tra un'entità padre (generale) e entità figlie (specializzate). Può essere Totale/Parziale (copertura delle istanze padre) e Esclusiva/Sovrapposta (intersezione delle istanze figlie),.

Esempi e Applicazioni

- **Relazione Ricorsiva:** Un'entità in relazione con se stessa (es. Impiegato "è capo di" Impiegato).
- **Esempio Residenza:** Relazione tra Persona e Comune. Cardinalità: Persona (1,1) (obbligatoria e unica), Comune (0,N) (opzionale e multipla).

Dettagli Minori

Relazioni Ternarie: Coinvolgono tre entità contemporaneamente. Si usano solo se il concetto non è riducibile a relazioni binarie (es. non manca mai un attore). Spesso si usano per storicizzare relazioni binarie introducendo il tempo,.

4 Progettazione Logica (Modello Relazionale)

Concetti Chiave

Il modello relazionale organizza i dati in Relazioni (tabelle). È un modello "value-based": i puntatori fisici non esistono, i legami tra dati avvengono copiando i valori delle chiavi (attributi identificanti) da una tabella all'altra. Una relazione è un insieme matematico di tuple (righe), quindi non ha ordinamento né duplicati,.

Definizioni

- **Superchiave:** Un insieme di attributi che identifica univocamente una tupla.
- **Chiave Candidata:** Una superchiave minimale (non contiene attributi superflui).
- **Chiave Primaria:** La chiave candidata scelta come identificatore principale.
- **Vincolo di Integrità Referenziale (Foreign Key):** Impone che i valori di un attributo in una tabella (es. NumTreno in FERMATA) debbano esistere come chiave primaria nell'altra tabella riferita (es. TRENO).

Esempi e Applicazioni (Anomalie)

Si analizza il caso di una "Relazione Unica" che mischia dati di Appartamenti e Proprietari.

- **Anomalia di inserimento:** Non posso inserire un proprietario se non ha ancora un appartamento (o devo usare valori nulli).
- **Anomalia di aggiornamento:** Se un proprietario cambia telefono, devo aggiornarlo su tutte le righe dei suoi appartamenti.
- **Soluzione:** Decomposizione in più tabelle (Appartamento, Proprietario, Proprietà) per eliminare ridondanze senza perdere informazioni.

Dettagli Minori

Valori Nulli (NULL): Indicano informazione inesistente o sconosciuta. Non possono stare nella chiave primaria,. Le chiavi esterne possono essere NULL se la partecipazione alla relazione è opzionale.

5 Progettazione Logica dallo Schema Concettuale

Titolo della sezione: Ristrutturazione e Traduzione

Concetti Chiave

Il passaggio da ER a Relazionale richiede due fasi:

- **Ristrutturazione:** Si adatta lo schema ER perché certi costrutti (generalizzazioni, attributi multivalore/composti) non esistono nel relazionale.
- **Traduzione:** Applicazione meccanica di regole per creare tabelle.

Operazioni di Ristrutturazione

- **Analisi Ridondanze:** Decidere se mantenere dati derivabili (es. totale fattura) in base al carico di lavoro (costo lettura vs costo aggiornamento),.
- **Eliminazione Generalizzazioni:**
 - Accorpamento nel padre: Le figlie spariscono, i loro attributi vanno nel padre (diventano opzionali). Si aggiunge un attributo "Tipo".
 - Accorpamento nelle figlie: Il padre sparisce, i suoi attributi si duplicano nelle figlie (solo se generalizzazione totale).
 - Sostituzione con relazioni: Padre e figlie diventano tabelle separate collegate da relazioni 1:1.
- **Partizionamento:** Spezzare un'entità in due (verticalmente) per efficienza di accesso.

Regole di Traduzione (ER $\rightarrow$ Relazionale)

- Entità $\rightarrow$ Tabella.
- Relazione Molti-a-Molti $\rightarrow$ Nuova tabella contenente le chiavi primarie delle due entità collegate,.
- Relazione Uno-a-Molti $\rightarrow$ Non si crea una nuova tabella. La chiave dell'entità lato "uno" viene copiata (come chiave esterna) nella tabella dell'entità lato "molti".
- Relazione Uno-a-Uno $\rightarrow$ Si accorpa in una delle due tabelle (preferibilmente quella con partecipazione obbligatoria per evitare NULL).

Esempi

- **Accorpamento:** Un'entità E_0 (Padre) e E_1, E_2 (Figlie) diventano una sola tabella E con un attributo discriminante "D",.
- **Traduzione M:N:** Due entità E_1 (chiave a) e E_2 (chiave g) collegate da R generano 3 tabelle: $E_1(a...)$, $E_2(g...)$ e $R(a, g)$.

6 Tecnologie NoSQL: Sistemi Document Based

Concetti Chiave

I sistemi NoSQL (es. MongoDB) gestiscono dati semi-strutturati e sono progettati per scalabilità e flessibilità. Il modello Document-Store organizza i dati in collezioni di documenti (solitamente JSON). A differenza del relazionale ("piatto"), i documenti supportano strutture nidificate (embedding),.

Progettazione nei Document Store

La scelta fondamentale è tra:

- **Riferimenti (Normalization):** Simile al relazionale. I documenti sono collegati tramite ID. Evita ridondanza ma richiede più query per recuperare dati collegati.
- **Nidificazione (Embedding):** Un documento contiene al suo interno i dati correlati (es. lo studente contiene la lista dei suoi esami). Ottimizza la lettura ma può creare ridondanza.

Regole di Traduzione (ER -> Documenti)

Si identificano le Entità Principali (EP) che diventano Collezioni (file di documenti). Le altre entità vengono trattate in base alle cardinalità: Se un'entità E_i è "debole" o legata strettamente a una EP, viene incapsulata. Si usano etichette per indicare la qualità della traduzione:

- X: Incapsulamento pulito (relazione 1:1 o 1:N lato figlio).
- L (Loss): Perdita di dati (es. relazione 0:1, se il padre non c'è, il figlio non può esistere nel documento).
- R (Redundancy): Ridondanza (es. relazione N:M o 1:N lato padre, il dato viene duplicato in più documenti),,,

Esempi

- **Embedding:** Studente contiene un array Esami: [{corso: "Basi", voto: 25}, ...].
- **Referencing:** Studente ha `_id`: 101. Esame è un documento separato con `studente_id`: 101.

7 Algebra Relazionale

Concetti Chiave

È un linguaggio procedurale (descrive come ottenere i dati) usato come base teorica per SQL. È costituito da un insieme di operatori che prendono relazioni in input e producono relazioni in output.

Definizioni e Operatori

Operatori Insiemistici: Richiedono schemi compatibili (stessi attributi).

- Unione ($\cup$): Somma le tuple di due relazioni.

- Differenza ($-$): Tuple presenti nella prima ma non nella seconda.
- Intersezione ($\cap$): Tuple comuni a entrambe.

Operatori Specifici:

- Ridenominazione (ρ): Cambia i nomi degli attributi per permettere operazioni insiemistiche o auto-join.
- Selezione (σ): Filtro orizzontale. Seleziona le righe che soddisfano una condizione logica (es. $\text{Età} > 18$).
- Proiezione (Π): Filtro verticale. Seleziona solo alcune colonne, rimuovendo i duplicati risultanti.
- Giunzione (Join $\bowtie$): Combina tuple di due relazioni diverse. Il Join Naturale unisce le tuple che hanno valori uguali negli attributi con lo stesso nome.

Esempi e Applicazioni

Query: "Trova i treni FR per Milano". **Algebra:** $\Pi_{\text{Numero}, \text{Ora}}(\sigma_{\text{Cat}='FR' \wedge \text{Dest}='Milano'}(TREN0))$.
 Questa operazione prima filtra le righe (Selezione) e poi tiene solo le colonne Numero e Ora (Proiezione).